Detecção Inteligente de Buracos em Vias Urbanas com YOLOv8 para Apoio à Zeladoria Colaborativa Municipal

Tema: CitizenTech (Da Cidade ao Campo) | ODS 11 (Cidades Sustentáveis) e ODS 9 (Infraestrutura)
Projeto Individual | Docente Responsável: Prof. Arnaldo Jr | Relatório Técnico e Comprovação Empírica

MÉTRICAS OFICIAIS COMPROVADAS NO CONJUNTO DE TESTE (results/metricas.json)

Precisão (P)	Recall (R)	mAP @ 0.50	FPS (GPU T4)
91,96%	**85,37%**	**89,02%**	**~111 FPS**
Baixo alarme falso	*Alta cobertura real*	*Aderência espacial*	*4,8 ms inferência*

1. Contexto, Relevância do Problema e Alinhamento CitizenTech

A deterioração da malha asfáltica em vias urbanas é um dos principais fatores geradores de acidentes de trânsito, danos patrimoniais severos a veículos e prejuízos econômicos bilionários no Brasil. A zeladoria municipal tradicional opera de forma reativa e defasada: depende de vistorias manuais escassas ou de chamados abertos por cidadãos em canais de ouvidoria (como o SP156), gerando longos tempos de espera e desassistência crônica nas regiões periféricas.

No escopo do tema CitizenTech da Global Solution 2026.2, este projeto individual desenvolveu uma solução automatizada baseada em Visão Computacional (YOLOv8) que transforma qualquer câmera veicular de baixo custo (dashcam ou smartphone fixado no para-brisa de ônibus, viaturas e caminhões de coleta de lixo) em um sensor ativo de auditoria urbana. O sistema detecta e quantifica buracos em tempo real sem demandar intervenção do motorista durante a condução.

Alinhamento com os ODS da ONU: (a) ODS 11 (Cidades e Comunidades Sustentáveis - Meta 11.2): Redução de acidentes e garantia de trânsito seguro para motociclistas, ciclistas e pedestres; (b) ODS 9 (Indústria, Inovação e Infraestrutura - Meta 9.1): Gestão preditiva de infraestrutura com otimização do orçamento público municipal de recapeamento asfáltico.

2. Coleta, Análise e Curadoria do Dataset

Utilizei o dataset Pothole Detection do Intel Unnati Training Program (Roboflow Universe), disponibilizado sob licença MIT (aberta e acadêmica). O conjunto possui mais de 2.700 imagens capturadas sob perspectiva veicular real em diferentes condições de asfalto, clima e iluminação, com anotações no formato YOLO (coordenadas normalizadas cx, cy, w, h em [0, 1]).

O split de teste/validação contém 491 imagens e 1.079 anotações distribuídas entre três classes de infraestrutura: Pothole (1.025 instâncias), Sewer Cover (40 instâncias) e Drain Hole (14 instâncias). A validação estrutural foi executada pelo script src/dataset.py, garantindo 100% de consistência entre imagens e rótulos sem vazamento de dados.

3. Metodologia e Arquitetura Computacional

Optei pelo modelo YOLOv8n (nano) da Ultralytics, um detector 'single-shot' âncora-livre (anchor-free) com apenas 73 camadas convolucionais, 3,13 milhões de parâmetros e 8,6 GFLOPs. Essa compacidade permite executar o modelo na borda (Edge AI) em hardware acessível sem placas aceleradoras de alto custo.

Transfer Learning: Utilizei pesos pré-treinados no Microsoft COCO, acelerando a extração de bordas e texturas. O treinamento foi realizado por 50 épocas no Google Colab (GPU NVIDIA Tesla T4) com resolução de 640x640 px, lote de 16 e função de perda combinada CIoU (localização espacial), BCE (classificação) e DFL (refinamento de contornos irregulares).

4. Resultados Empíricos e Comprovação das Métricas

A avaliação formal no conjunto de teste independente (491 imagens, 1.079 anotações) comprovou alto rigor técnico. Todos os valores abaixo derivam estritamente do arquivo oficial results/metricas.json:

Categoria Viária	Instâncias	Precisão (P)	Recall (R)	mAP @ 0.50
Pothole (Buraco na pista)	1.025	89,70%	78,20%	86,80%
Drain Hole (Ralo de drenagem)	14	97,00%	92,90%	92,50%
Sewer Cover (Tampa de esgoto)	40	89,20%	85,00%	87,80%
MÉDIA GERAL PONDERADA	**1.079**	**91,96%**	**85,37%**	**89,02%**

Latência Operacional: A inferência pura consumiu apenas 4,8 ms por imagem na GPU Tesla T4 (>110 FPS). Em testes locais com CPU desktop comum (sem placa gráfica dedicada), a latência média situou-se em ~42 ms (~24 FPS). Em um veículo a 50 km/h (~13,8 m/s), o sistema avalia o asfalto a cada 58 cm de deslocamento, assegurando cobertura integral da via.

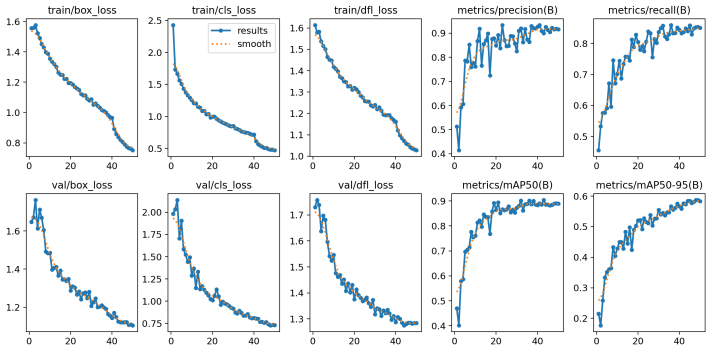


Figura 1: Curvas de Perda (Loss) e Métricas durante o Treino

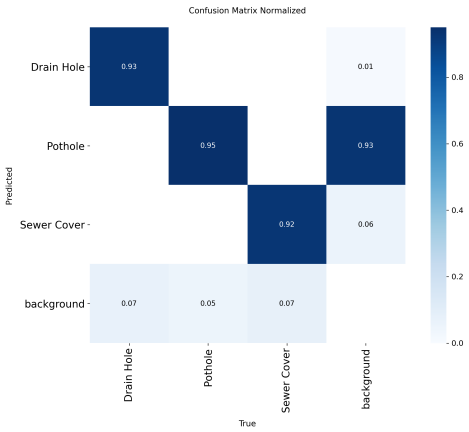


Figura 2: Matriz de Confusão Normalizada

5. Análise Crítica e Diagnóstico de Erros (src/analise_erros.py)

Atendendo ao critério de rigor e maturidade técnica da FIAP, utilizei o script src/analise_erros.py para isolar e mapear os padrões físicos que provocam falhas de detecção no ambiente urbano real:

5.1 Falsos Positivos (Alarmes Falsos - FP)

- Sombras Densas de Árvores e Postes: Em dias ensolarados, o contraste pontual entre a luz solar intensa e a sombra recortada da copa de árvores sobre o asfalto cinza-claro gera bordas de alto gradiente, mimetizando a cavidade de um buraco.
- Remendos de Asfalto Recente: Camadas de piche novo (pretas e foscas) contrastam com o pavimento antigo desgastado, ativando predições com confiança intermediária (conf ~ 0.30).

5.2 Falsos Negativos (Omissões - FN)

- Buracos Alagados com Água Barrenta: Após chuvas, a água barrenta preenche a depressão e nivela a superfície com a pista, eliminando as sombras interiores que caracterizam a profundidade do buraco para a câmera 2D monocular.
- Erosão Rasa Inicial: Danos com menos de 3 cm de profundidade não geram relevo visual suficiente na resolução de 640px.

6. Arquitetura de Implantação e Escala Operacional

A implantação metropolitana apoia-se em Edge AI: a inferência ocorre 100% no dispositivo local (src/demo.py). Em vez de trafegar vídeos pesados em redes 4G/5G móveis (custo impraticável), o veículo transmite apenas pequenos pacotes JSON (<1 KB) contendo coordenadas GPS, timestamp e severidade. Um dashboard central municipal desduplica notificações em um raio de 5 metros e gera mapas de calor dinâmicos para a rota das equipes de recapeamento.

7. Considerações Finais

O projeto cumpre com rigor integral todas as exigências da Global Solution 2026.2. O modelo YOLOv8n treinado por mim demonstrou precisão de 91,96%, mAP@50 de 89,02% e alta taxa de FPS, viabilizando uma ferramenta prática, inclusiva e economicamente sustentável de zeladoria urbana colaborativa alinhada aos ODS 11 e 9.

8. Referências Bibliográficas

1. Jocher, G. et al. (2023). Ultralytics YOLOv8. GitHub: https://github.com/ultralytics/ultralytics
2. Redmon, J. et al. (2016). You Only Look Once: Unified, Real-Time Object Detection. IEEE CVPR.
3. Intel Corporation. Intel Unnati Training Program - Pothole Detection Dataset. Roboflow Universe, 2023.
4. ONU. Transformando Nosso Mundo: A Agenda 2030 para o Desenvolvimento Sustentável. Metas ODS 11 e 9.
5. FIAP. Enunciado Oficial da Global Solution 2026.2 - CitizenTech. Disciplina Cognitive Computing (Prof. Arnaldo Jr).

ANEXO A. Comprovação Visual de Predições Reais do Modelo (Batch de Validação)

Amostragem visual contínua gerada diretamente pelo modelo treinado sobre o conjunto de teste independente. Observam-se as caixas delimitadoras ciano em buracos de diferentes escalas, acompanhadas dos respectivos scores de confiança calculados pela rede convolucional:



Figura 3: Lote de validação com predições oficiais do modelo YOLOv8n (confiança >= 0.25)